



Clasificación Arancelaria con Procesamiento de Lenguaje Natural

Plan de tesis

Maestría en Explotación de Datos y Generación del Conocimiento - UBA

Tesista: Santiago Sebastian Tedoldi

Director: Dr. Bruno Bianchi

Fecha: 30 de Septiembre de 2025

Contexto

El comercio mundial alcanzó en 2024 un récord cercano a los 33 billones de dólares, con una expansión del 3,7 %. Este dinamismo convive con una creciente diversidad de bienes (alimentos, químicos, fármacos, dispositivos tecnológicos, entre otros), lo que eleva la complejidad de identificar correctamente cada producto en los regímenes de comercio exterior.

Para ordenar ese universo, la mayoría de los países utiliza el **Sistema Armonizado (HS)**, adoptado por más de 190 jurisdicciones y que cubre cerca del 98 % del comercio global. El HS organiza los bienes en capítulos (HS02), partidas (HS04) y subpartidas (HS06), con 1.244 partidas y 5.612 subpartidas en su versión 2022.

En Argentina, además, la declaración a consumo utiliza el **código SIM** de 11 dígitos (HS06 + NCM + dígitos nacionales), con un universo de ~30 mil códigos locales. Por ejemplo, el código SIM de teléfonos inteligentes (VUCE, 2025):

Código Argentino	SIM				
Código MERCOSUR	NCM				
Subheadings HS	HS06				
Headings HS	HS04				
Chapter HS	HS02				
Teléfonos inteligentes	85	17	13	00	000 C

La correcta clasificación es crítica: una inexactitud puede acarrear multas relevantes y desvíos en tratamientos arancelarios o intervenciones de otros organismos. La propia magnitud y granularidad del nomenclador hacen que encontrar el código correcto sea un desafío operativo importante.

Problema abordado y motivación

La tesis busca **asistir la clasificación arancelaria** de mercaderías a nivel **HS04** a partir de **descripciones comerciales en texto libre**. El caso de estudio utiliza un dataset de ~500 mil pares (descripción, código) en inglés, proveniente de una capacitación internacional (programa BACUDA de la OMA). El problema es **multiclase**, con **miles de etiquetas** y **alto desbalanceo**. La pregunta central es si, con estos datos, puede entrenarse un recomendador de códigos con precisión útil para la práctica aduanera.

Antecedentes

Para el Taller de Tesis 1 de la Maestría, se entrenó un clasificador con **DistilBERT** (transfer learning, *fine-tuning* parcial y total) para **HS04**, obteniendo aprox. **Top-1 ≈ 64 %** y **Top-5 ≈ 82 %**.

Enfoque metodológico

El trabajo compara dos grandes familias de representaciones de texto:

- **Representaciones distribuidas “clásicas”** (e.g., **Doc2Vec** y **FastText**) como líneas de base robustas y ampliamente estudiadas.
- **Modelos tipo *transformer*** (p.ej., **DistilBERT**), que permiten capturar contexto y relaciones semánticas más ricas en textos breves y heterogéneos.

El plan contempla **preprocesos simples** (limpieza, normalización, variantes con/ sin stopwords y n-gramas cuando apliquen) y **evaluaciones controladas** bajo un protocolo común de particiones, semillas y métricas. Adicionalmente, se realizarán **estudios de error** por sección del HS, y **curvas cobertura-precisión** para entender cuándo el sistema es confiable.

Nota sobre alcance: se trabaja en **HS04**, nivel que balancea granularidad y operatividad. El propio HS habilita pensar la tarea en 4 o 6 dígitos; aquí se prioriza el **nivel de partida (4 dígitos)** como primer objetivo práctico, dejando puertas abiertas para profundizaciones posteriores.

Plan de trabajo y entregables

Fase 1 — Diciembre 2025: Ablaciones de preprocesamiento + baselines

- Diagnóstico de calidad y sesgos; variantes con/sin normalizaciones sencillas.
- Entrenamiento y evaluación de **Doc2Vec** y **FastText** como **líneas de base**.
- Entregables: reporte comparativo inicial (tablas y gráficos básicos), lecciones de ablación.

Fase 2 — Febrero 2026: *Transformers* + comparativa integral + error

- Entrenamiento y evaluación del enfoque *transformer*.
- **Cuadro comparativo integral** (baselines vs *transformer*), con métricas Top-N; **análisis de confusiones** por secciones y **curvas de confianza**.

Fase 3 — Marzo 2026: Redacción y documentación

- Redacción completa (metodología, resultados, límites, reproducibilidad).
- Se incorporan buenas prácticas y trazabilidad de experimentos.

Fase 4 — Abril 2026: Presentación y defensa

- Síntesis ejecutiva con **insights accionables** (dónde acierta mejor, dónde duda, cómo integrarlo en flujo operativo).

Riesgos principales y mitigaciones

1. **Desbalance de clases** (muchas partidas poco frecuentes).

Mitigación: métricas macro/weighted, particiones estratificadas, y análisis por sección del HS para no “ocultar” clases minoritarias.

2. **Calidad/ambigüedad de descripciones** (textos cortos, ruidosos).

Mitigación: variantes de limpieza mínimas y estudio de confianza por caso; priorizar **Top-N** y reportes de cobertura; recomendaciones para mejora de datos en origen.

3. **Sobreajuste y estabilidad** de resultados.

Mitigación: protocolos de evaluación consistentes, semillas fijadas y validaciones por *split*; evitar complejidad innecesaria en preprocesos.

4. **Limitación del corpus** frente a la complejidad del HS.

Mitigación: foco inicial en HS04; discusión explícita de **data needs** para escalar (millones de descripciones) y robustecer.

Resultados esperados y contribuciones

1. **Baseline comparado y justificado:** cuantificación clara del **valor incremental** de *transformers* frente a baselines “clásicos” para HS04 (Top-N y métricas balanceadas).
2. **Entendimiento accionable del error:**
 - Mapas de confusión por sección del HS.
 - Curvas confianza-cobertura para **definir umbrales operativos**.
 - Recomendaciones para mejorar la **calidad de descripciones**.
3. **Transferencia institucional:** documento de buenas prácticas y anexos para facilitar continuidad e iteraciones futuras.

Consideraciones éticas y de datos

Se trabajará con **textos no identificables**, respetando la normativa vigente. La tesis no busca reemplazar la decisión experta, sino **asistirla**: cuando el sistema no tenga confianza suficiente, **deberá intervenir la revisión humana**. El objetivo es **reducir errores**, acelerar tareas repetitivas y liberar tiempo experto para casos complejos.