



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES

Clasificación arancelaria con procesamiento de lenguaje natural

Tesis presentada para optar al título de Magister en
Explotación de Datos y Descubrimiento de Conocimiento

Tesista: Ing. Santiago S. Tedoldi
Director: Dr. Bruno Bianchi

Buenos Aires, 10 de noviembre de 2025

Contexto

El comercio mundial alcanzó en 2024 un récord cercano a los 33 billones de dólares, con una expansión del 3,7 %. Este dinamismo convive con una creciente diversidad de bienes (alimentos, químicos, fármacos, dispositivos tecnológicos, entre otros), lo que eleva la complejidad de identificar correctamente cada producto en los regímenes de comercio exterior.

Para ordenar ese universo, la mayoría de los países utiliza el Sistema Armonizado (HS), adoptado por más de 190 jurisdicciones y que cubre cerca del 98 % del comercio global. El HS organiza los bienes en capítulos (HS02), partidas (HS04) y subpartidas (HS06), con 1.244 partidas y 5.612 subpartidas en su versión 2022.

En Argentina, además, la declaración a consumo utiliza el código SIM de 11 dígitos (HS06 + NCM + dígitos nacionales), con un universo de ~30 mil códigos locales. Por ejemplo, el código SIM de teléfonos inteligentes (VUCE, 2025):

Código Argentino	SIM				
Código MERCOSUR	NCM				
Subheadings HS	HS06				
Headings HS	HS04				
Chapter HS	HS02				
Teléfonos inteligentes	85	17	13	00	000 C

La correcta clasificación es crítica: una inexactitud puede acarrear multas relevantes y desvíos en tratamientos arancelarios o intervenciones de otros organismos del estado. La propia magnitud y granularidad del nomenclador hacen que encontrar el código correcto sea un desafío operativo importante.

En este escenario, la explotación de datos, y más particularmente las técnicas de procesamiento de lenguaje natural (NLP) o minería de texto, pueden aportar a la solución de la problemática. Para esto, disponemos de diversos algoritmos de aprendizaje automático que pueden clasificar a las mercaderías partiendo de sus descripciones en lenguaje natural.

El modelo Doc2Vec (Le, 2014), como una extensión del propio Word2Vec (Mikolov, 2013), permite representar vectorialmente (*embedding*) a las descripciones de las mercaderías para luego clasificarlas por medidas de similitud. Mientras tanto, FastText (Bojanowski, 2017) presenta una oportunidad similar, con la ventaja de procesar subpalabras en lugar de palabras completas como hace Doc2Vec. Se puede decir que es una evolución de Word2Vec con avances en la tokenización empleada.

Por otro lado, en el auge extendido de los modelos de lenguaje basados en Transformers, BERT (Devlin, 2019) y sus algoritmos derivados, presentan otro set de técnica para representar a las descripciones en cuestión. Estos, permiten además el aprovechamiento de modelos *opensource* preentrenados con corpus extensos, siendo muy utilizados en técnicas de Transfer Learning.

Finalmente, corresponde destacar que mediante fuentes como HuggingFace, la democratización de estos modelos (y muchos otros) es un hecho. DistilBERT (Sanh, 2020), un modelo preentrenado con un BERT como maestro, es una opción óptima para el desarrollo de herramientas donde la capacidad de cómputo es escasa y las aplicaciones pueden requerir una rápida inferencia.

Problema abordado y motivación

La tesis busca asistir la clasificación arancelaria de mercaderías a nivel HS04 a partir de descripciones comerciales en texto libre. El caso de estudio utiliza un dataset de ~500 mil pares (descripción, código) en inglés, proveniente del proyecto BACUDA (OMA, 2025). El problema es multiclase, con miles de etiquetas y alto desbalanceo. La pregunta central es si, con estos datos, puede entrenarse un recomendador de códigos con precisión útil para la práctica aduanera.

Objetivos

Objetivo general: Entrenar un modelo de clasificación que logre recomendar códigos HS04 partiendo de descripciones comerciales de mercaderías.

Objetivos específicos:

1. **Preprocesamiento:** normalización, *stopwords*, n-gramas; medir cuándo ayudan/perjudican la clasificación.
2. **Baselines:** entrenar y evaluar **Doc2Vec** y **FastText** para cuantificar el valor incremental de **Transformers**.
3. **Análisis del error:** identificar patrones de confusión por capítulo/partida y casos “difíciles”.

Antecedentes

Para el Taller de Tesis 1 de la Maestría, esta problemática fue abordada entrenando un clasificador con **DistilBERT** como *encoder* y una red neuronal como clasificador. Se evaluaron 3 técnicas de Transfer Learning: uso del *encoder* preentrenado, ajustando 2 capas del *encoder* y un *fine-tuning* total del mismo. La clasificación se hizo a nivel de partida armonizada (códigos HS04), obteniendo resultados alentadores, superadores para el *fine-tuning* total del conjunto *encoder-classifier*.

La medición de performance se definió observando la salida del clasificador, tomando las probabilidades sobre cada código HS04 en orden descendiente. Comparando los códigos más probables con el código correcto, se puede evaluar la tasa de acierto en los TopN. El modelo ganador del trabajo de Taller de Tesis 1 obtuvo en **Top-1** $\approx 64\%$ y en **Top-5** $\approx 82\%$.

Enfoque metodológico

El trabajo compara dos grandes familias de representaciones de texto:

- **Representaciones distribuidas “clásicas”** (e.g., **Doc2Vec** y **FastText**) como líneas de base robustas y ampliamente estudiadas.
- **Modelos tipo transformer** (p.ej., **DistilBERT**), que permiten capturar contexto y relaciones semánticas más ricas en textos breves y heterogéneos.

El plan contempla **preprocesos simples** (limpieza, normalización, variantes con/ sin *stopwords* y n-gramas cuando apliquen) y **evaluaciones controladas** bajo un protocolo común de particiones, semillas y métricas. Adicionalmente, se realizarán **estudios de**

error por sección del HS, y **curvas cobertura-precisión** para entender cuándo el sistema es confiable.

Nota sobre alcance: se trabaja en **HS04**, nivel que balancea granularidad y operatividad. El propio HS habilita pensar la tarea en 4 o 6 dígitos; aquí se prioriza el **nivel de partida (4 dígitos)** como primer objetivo práctico, dejando puertas abiertas para profundizaciones posteriores.

Plan de trabajo y entregables

Fase 1 — noviembre 2025: Ablaciones de preprocesamiento + baselines

- Diagnóstico de calidad y sesgos; variantes con/sin normalizaciones sencillas.
- Entrenamiento y evaluación de Doc2Vec y FastText como líneas de base.

Fase 2 — febrero 2026: Transformers + comparativa integral + error

- Entrenamiento y evaluación del modelo Transformer.
- Cuadro comparativo integral (baselines vs transformer), con métricas Top-N; análisis de confusiones por secciones y curvas de confianza.

Fase 3 — marzo 2026: Redacción y documentación

- Redacción completa (metodología, resultados, límites, reproducibilidad).

Fase 4 — abril 2026: Presentación y defensa

- Síntesis ejecutiva con descubrimientos accionables (dónde acierta mejor, dónde duda, cómo integrarlo en flujo operativo).

Riesgos principales y mitigaciones

Desbalance de clases (muchas partidas poco frecuentes).

Mitigación: métricas macro/*weighted*, particiones estratificadas, y análisis por sección del HS para no “ocultar” clases minoritarias.

Calidad/ambigüedad de descripciones (textos cortos, ruidosos).

Mitigación: variantes de limpieza mínimas y estudio de confianza por caso; priorizar **Top-N** y reportes de cobertura; recomendaciones para mejora de datos en origen.

Sobreajuste y estabilidad de resultados.

Mitigación: protocolos de evaluación consistentes, semillas fijadas y validaciones por *split*; evitar complejidad innecesaria en preprocesos.

Limitación del corpus frente a la complejidad del HS.

Mitigación: foco inicial en HS04; discusión explícita de **data needs** para escalar (millones de descripciones) y robustecer.

Resultados esperados y contribuciones

1. **Baseline comparado y justificado:** cuantificación clara del **valor incremental** de

transformers frente a baselines “clásicos” para HS04 (Top-N y métricas balanceadas).

2. **Entendimiento accionable del error:**

Mapas de confusión por sección del HS.

Curvas confianza-cobertura para definir umbrales operativos.

Recomendaciones para mejorar la calidad de descripciones.

3. **Transferencia institucional:** documento de buenas prácticas y anexos para facilitar continuidad e iteraciones futuras.

Consideraciones éticas y de datos

Se trabajará con **textos no identificables**, respetando la normativa vigente. La tesis no busca reemplazar la decisión experta, sino **asistirla**: cuando el sistema no tenga confianza suficiente, **deberá intervenir la revisión humana**. El objetivo es **reducir errores**, acelerar tareas repetitivas y liberar tiempo experto para casos complejos.

Referencias

Bojanowski (2017). Enriching Word Vectors with Subword Information.

Devli (2019). Pre-training of Deep Bidirectional Transformers for Language Understanding.

Le (2014). Distributed Representations of Sentences and Documents.

Mikolov (2013). Efficient Estimation of Word Representations in Vector Space.

OMA (2025). WCO BACUDA Project. Retrieved from <https://bacuda.wcoomd.org/>

Sanh (2020). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter.

VUCE (2025). Retrieved from Ventanilla Única del Comercio Exterior - Argentina: <https://www.vuce.gob.ar/>