

Trabajo práctico – Búsqueda de Bibliografía

Taller de Tesis II Maestría en Explotación de Datos y Descubrimiento de Conocimiento UBA

Alumno: Santiago Tedoldi

Descripción: Trabajo orientado al proyecto de tesis denominado “clasificación arancelaria con procesamiento de lenguaje natural”, cuyo director es el Dr. Bruno Bianchi. Se presenta el **contexto**, problema, objetivos y **antecedentes**, usando las técnicas de búsqueda bibliográfica aprendidas en Taller de Tesis II.

Contexto

En los últimos años, el comercio internacional se ha acelerado alcanzando volúmenes récord y una creciente fragmentación de las cadenas globales de valor. En 2024, el volumen de comercio alcanzó un récord cercano a los 33 billones de dólares, un 3,3 % superior al año previo [1]. Este dinamismo convive con una creciente diversidad de bienes (alimentos, químicos, fármacos, dispositivos tecnológicos, entre otros), lo que eleva la complejidad de identificar correctamente cada producto en los regímenes de comercio exterior.

Para ordenar ese universo de bienes, existe el Sistema Armonizado de Designación y Codificación de Mercancías (HS, por sus siglas en inglés), desarrollado por la Organización Mundial de Aduanas (OMA/WCO), y adoptado por más de 190 países y bloques económicos como base para sus aranceles y estadísticas de comercio [2]. El HS (versión 2022) comprende:

- 97 categorías de bienes definidas a dos dígitos (capítulos o HS02)
- 1.244 grupos de bienes definidos a cuatro dígitos (partidas o HS04)
- 5.612 subgrupos definidos a seis dígitos (subpartidas o HS06)

En Argentina, además, la declaración a consumo utiliza el código SIM de 11 dígitos (subpartida HS06 + NCM + dígitos nacionales), con un universo de ~30 mil códigos locales. Por ejemplo, el código SIM de teléfonos inteligentes es 8517.13.00.000C [3]:

Código Argentino	SIM				
Código MERCOSUR	NCM				
Subpartida HS	HS06				
Partida HS	HS04				
Capítulo HS	HS02				
Teléfonos inteligentes	85	17	13	00	000 C

Cabe destacar que, en cualquier jurisdicción o país, la correcta clasificación es crítica: una inexactitud puede acarrear multas relevantes y desvíos en tratamientos arancelarios o intervenciones de otros organismos del estado. Para Argentina, una clasificación incorrecta se enmarca como una declaración inexacta del Artículo 954 del Código Aduanero.

Por otro lado, de nuevo en el plano global, las empresas y los operadores del comercio internacional, responsables de clasificar los productos, están experimentando una transformación de la forma de operar de la mano del e-commerce. Según la UNCTAD, el número de compradores en línea superó los 2,3 mil millones en 2021 y las ventas de comercio electrónico de 43 economías alcanzaron casi 27 billones de dólares en 2022, alrededor de un 10 % más que en 2021 [4].

Este crecimiento se refleja en un aumento significativo de envíos de bajo valor, pedidos fraccionados y descripciones comerciales breves, heterogéneas y, a veces, ambiguas. Para las administraciones de aduanas y para las empresas que participan en el comercio exterior, esto implica un volumen de decisiones de clasificación sin precedentes, muchas veces a partir de textos cortos y ruidosos.

La OMA, a través del proyecto BACUDA, subraya que la clasificación HS sigue siendo una de las tareas más difíciles del entorno aduanero, altamente dependiente de la pericia humana y fuente frecuente de errores y controversias [5] [6]. Los sistemas tradicionales —manuales, basados en reglas o en búsquedas keyword-driven— requieren incorporar herramientas inteligentes que permitan priorizar casos, sugerir códigos probables y documentar mejor el razonamiento, asistiendo la labor de los clasificadores humanos en lugar de sustituirla.

En este escenario, la explotación de datos, el aprendizaje automático y procesamiento de lenguaje natural (NLP) abren la posibilidad de modelar descripciones de los bienes mediante técnicas de embeddings (Word2Vec, Doc2Vec y FastText) [7] [8] [9] y modelos de lenguaje basados en Transformers como BERT [10] y sus variantes (por ejemplo, DistilBERT) [11] para construir clasificadores automáticos o asistidos que “lean” descripciones comerciales y sugieran códigos HS o NCM con buena precisión.

Pese a estos avances, la aplicación sistemática de estas técnicas sobre universos amplios de mercaderías —que cubran la mayor parte de la nomenclatura y escenarios operativos realistas— sigue siendo un desafío abierto, especialmente en contextos como el comercio electrónico transfronterizo y las operaciones minoristas.

Problema abordado y motivación

La tesis busca asistir la clasificación arancelaria de mercaderías a nivel HS04 a partir de descripciones comerciales en texto libre. El caso de estudio utiliza un dataset de ~500 mil pares (descripción, código) en inglés, proveniente del proyecto BACUDA [12]. El problema es multiclase, con miles de etiquetas y alto desbalanceo. La pregunta central es si, con estos datos, puede entrenarse un modelo recomendador de códigos con precisión útil para la práctica aduanera.

Objetivos

Objetivo general: Entrenar un modelo de clasificación que logre recomendar códigos HS04 partiendo de descripciones comerciales de mercaderías.

Objetivos específicos:

1. **Preprocesamiento:** normalización, *stopwords*, n-gramas; medir cuándo ayudan/perjudican la clasificación.
2. **Baselines:** entrenar y evaluar **Doc2Vec** y **FastText** para cuantificar el valor incremental de **Transformers**.

3. **Análisis del error:** identificar patrones de confusión por capítulo/partida y casos “difíciles”.

Antecedentes

Los primeros antecedentes relevantes provienen del desarrollo de métodos de representación distribuida de palabras y documentos. Word2Vec introdujo el uso de redes neuronales simples para aprender vectores de palabras a gran escala [7], mientras que Doc2Vec extendió esta idea a secuencias más largas, como oraciones y documentos [8]. Luego, para abordar la problemática de ruido y errores de tipeo, FastText presentó una forma de procesar subpalabras (particiones) o subtokens [9].

Estos enfoques permitieron construir clasificadores basados en embeddings a partir de texto libre, y han sido aplicados como baseline en tareas de categorización de productos tanto en comercio electrónico como en análisis de catálogos. Con el desarrollo de la arquitectura Transformers [13], BERT [10] y sus variantes (por ejemplo, DistilBERT) [11] incorporan representaciones contextuales bidireccionales, se han convertido en métodos muy difundidos para la clasificación de texto en dominios generales, partiendo de modelos pre-entrenados con distintas técnicas de transfer learning [14].

En el terreno específico de la clasificación arancelaria, la OMA y varias administraciones aduaneras han comenzado a experimentar con modelos de Machine Learning (ML) y Deep Learning (DL). El proyecto BACUDA de la OMA desarrolló un modelo neuronal para recomendación de códigos HS a partir de descripciones comerciales, que se integra en una plataforma demostrativa de recomendación de códigos y visualización de resultados [5] [12]. Sin embargo, la información pública disponible no expone detalles reproducibles sobre su desempeño o sobre conjuntos de datos abiertos.

Un desarrollo en Corea del Sur propone un modelo basado en KoELECTRA (una variante de BERT entrenado en coreano) para asistir a la clasificación HS, alcanzando un 95,5 % de precisión top-3 (aciertos en los primeros tres códigos sugeridos) sobre 129.084 casos históricos en 265 subpartidas [15]. Este trabajo demuestra la viabilidad de usar modelos de lenguaje combinados con sistemas de recuperación para referenciar la clasificación a textos del HS o a casos previos, pero su universo está acotado a un subconjunto de subpartidas (265 subpartidas es menos del 5 % de las comprendidas en el HS).

De forma contemporánea, el estudio del BID de Marra de Artiñano et al. evalúa distintos algoritmos (modelos clásicos de ML y GPT-3.5) sobre descripciones de productos agrícolas y alimentarios provenientes de organismos públicos (incluida información aduanera y del USDA) [16]. Los autores encuentran que los modelos tradicionales funcionan bien dentro del conjunto de datos en que se entrenan, incluso superando al LLM, pero su rendimiento cae abruptamente al transferirlos a casos de otros países/jurisdicciones. En cambio, GPT-3.5 exhibe una performance relativamente estable entre conjuntos y niveles de agregación HS, con accuracies del orden del 60–90 % según la cantidad de dígitos (HS04, HS02, etc.) definidos como target.

En una línea complementaria, Gholamian et al. abordan el problema de clasificación de productos para comercio y compliance en un entorno industrial real, evaluando el uso de LLMs con in-context learning frente a enfoques supervisados tradicionales [17]. Sus resultados muestran que los LLMs son robustos ante descripciones incompletas o perturbadas, pero (de nuevo) el estudio se centra en un conjunto de productos acotados, sin cubrir toda la amplitud de la nomenclatura HS.

Más recientemente, en el ámbito del comercio electrónico y el retail, se trabajó con un conjunto de datos jerárquico de más de un millón de productos del marketplace chino JD.com y los autores proponen HFT-BERT, un modelo BERT con fine-tuning jerárquico que mejora la clasificación de productos en una estructura de tres niveles de categorías [18]. Aunque trabaja con categorías de e-commerce y no con códigos HS, ilustra cómo los modelos basados en Transformers pueden aprovechar estructuras jerárquicas para mejorar la clasificación de catálogos grandes.

Por último, a fines del 2024 se propuso un benchmark comparativo de herramientas comerciales y modelos basados en ML/AI para clasificación HTS (HS de 10 dígitos) en el contexto de los Estados Unidos [19]. Aunque el documento aún no fue publicado por una revista, se trata de una iniciativa en la dirección acertada. Cabe también destacar que la autoría es unipersonal y de alguien vinculada a Tarifflo (una de las compañías dueña de una de las herramientas evaluadas), razones que motivan a una revisión/validación de la metodología empleada.

En síntesis, la literatura reciente muestra avances significativos en: (i) representaciones de texto y modelos de lenguaje aplicados a clasificación de productos, (ii) prototipos de clasificación HS en administraciones aduaneras, y (iii) aplicaciones de LLMs para escenarios de comercio y compliance. Sin embargo, estos estudios tienden a concentrarse en subconjuntos específicos de mercaderías, contextos lingüísticos particulares o herramientas aún en fase de consolidación. Esto deja abierta una oportunidad para desarrollar y validar clasificadores basados en NLP que cubran un espectro más amplio de mercaderías, que puedan integrarse a arquitecturas híbridas con LLMs (por ejemplo, esquemas RAG o de re-ranking experto) y que sean evaluados con métricas transparentes sobre datos representativos del comercio real, incluyendo e-commerce transfronterizo.

Bibliografía

- [1] UNCTAD, “Global Trade Update,” 2024. [Online]. Available: <https://unctad.org/publication/global-trade-update-december-2024>. [Accessed 10 11 2025].
- [2] WCO - World Customs Organization, “What is the Harmonized System (HS)?,” 2025. [Online]. Available: <https://www.wcoomd.org/en/topics/nomenclature/overview/what-is-the-harmonized-system.aspx>. [Accessed 10 11 2025].
- [3] Ministerio de Economía - República Argentina, «Ventanilla Única del Comercio Exterior,» 29 06 2025. [En línea]. Available: <https://www.vuce.gob.ar/>. [Último acceso: 11 7 2025].
- [4] UNCTAD, “Business e-commerce sales and the role of online platforms,” 2024. [Online]. Available: <https://unctad.org/publication/business-e-commerce-sales-and-role-online-platforms>. [Accessed 10 11 2025].
- [5] WCO - World Customs Organization, “How Artificial Intelligence (AI) can help Customs in automating HS Classification,” 2022. [Online]. Available: <https://www.wcoomd.org/en/media/newsroom/2022/april/how-ai-can-help-customs-in-automating-hs-classification.aspx>. [Accessed 10 11 2025].
- [6] A. Grainger, “Customs Tariff Classification and the Use of Assistive Technologies,” *World Customs Journal*, vol. 18, no. 2, 2024.
- [7] T. Mikolov, K. Chen, G. Corrado and J. Dean, “Efficient Estimation of Word Representations in Vector Space,” 2013. [Online]. Available:

<https://arxiv.org/abs/1301.3781>. [Accessed 10 11 2025].

- [8] Q. V. Le and T. Mikolov, "Distributed Representations of Sentences and Documents," in *International Conference on Machine Learning (ICML)*, 2014.
- [9] P. Bojanowski, E. Grave, A. Joulin and T. Mikolov, "Enriching Word Vectors with Subword Information," *Transactions of the Association for Computational Linguistics*, vol. 5, 2017.
- [10] J. Devlin, M. W. Chang, K. Lee and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *NAACL-HLT*, 2019.
- [11] V. Sanh, L. Debut, J. Chaumond and T. Wolf, "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter," 2020. [Online]. Available: <https://arxiv.org/abs/1910.01108>. [Accessed 10 11 2025].
- [12] WCO - World Customs Organization, "WCO BACUDA Project," 26 10 2025. [Online]. Available: <https://bacuda.wcoomd.org/>. [Accessed 10 11 2025].
- [13] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser and I. Polosukhin, "Attention Is All You Need," *Neural Information Processing Systems*, 2017.
- [14] C. Sun, X. Qiu, Y. Xu and X. Huang, "How to Fine-Tune BERT for Text Classification?," in *Chinese Computational Linguistics (CCL 2019), Lecture Notes in Computer Science*, vol. 11856, 2019.
- [15] E. Lee, S. Kim, S. Kim, S. Jung, H. Kim and M. Cha, "Explainable Product Classification for Customs," 2023.
- [16] I. Marra de Artiñano, F. Riottini Depetris and C. Volpe Martincus, "Automatic Product Classification in International Trade: Machine Learning and Large Language Models," 2023. [Online]. Available: <https://publications.iadb.org/en/automatic-product-classification-international-trade-machine-learning-and-large-language-models>. [Accessed 11 10 2025].
- [17] S. Gholamian, G. Romani, B. Rudnikowicz and S. Skylaki, "LLM-Based Robust Product Classification in Commerce and Compliance," in *CustomNLP4U*, Miami, Florida, USA, 2024.
- [18] K. Liu, T. Liu, F. Wang and R. Pan, "A BERT-based Hierarchical Classification Model with Applications in Chinese Commodity Classification," 2025. [Online]. Available: <https://arxiv.org/abs/2508.15800>. [Accessed 10 11 2025].
- [19] B. Judy, "Benchmarking Harmonized Tariff Schedule Classification Models," 2024. [Online]. Available: <https://arxiv.org/abs/2412.14179>. [Accessed 10 11 2025].